

OPPO 端侧多模态大模型 工程化实践

余席宇

OPPO 多模态算法专家

AiCon

全球人工智能开发与应用大会

极客邦科技 2026 年会议规划

促进软件开发及相关领域知识与创新的传播



参会咨询

InfoQ 技术大会

QCon 上海站
全球软件开发大会

大模型正在重新定义软件
Large Language Model Is Redefining
The Software

10月22-24日 / 上海建工浦江皇冠假日酒店

· AI Agent

· Vibe Coding

· 智能可观测

· 推理基建

· 模型攻防

· AI x 创造力

InfoQ 技术大会

AiCon 北京站
全球人工智能开发与应用大会

探索 AI 应用边界
Explore the limits of AI applications

12月18-19日 / 北京

· 大模型架构创新

· 多模态 AI 产业融合

· 具身智能

· AI for Science

· 大模型安全

目录

- 01 端侧化技术概览
- 02 量化感知训练架构
- 03 QALFT 工程化架构
- 04 端侧训练算法
- 05 落地实践
- 06 总结与展望

01 端侧化技术概览



端侧化核心挑战



端侧算力、内存与功耗预算有限，大模型易“装不下、跑不动、撑不久”。需在体量、精度、时延、温升与续航间折中，通过压缩、缓存和解码优化保证持续可用。

内存 / 时延 / 功耗
瓶颈



从训练到端上部署，需经转换、量化、多芯片适配与机型验证。任一环节偏差都可能效果回退，跨团队协作成本高，迭代易被链路拖慢。

工程链路复杂



多业务常共用基座模型以省 ROM，基座一改需多线同步联调验收。算法、工程与业务强绑定，难独立演进，发布与回归成本显著上升。


业务耦合严重



端侧能力固化后，难像云端按人群与场景灵活试错；OTA 贵、反馈弱，个性化难闭环。交付须一次做对，个性化长期成短板。

个性化需求难覆盖

端侧化工程实践



02 量化感知训练架构

■ 量化感知训练架构

目标：低比特 / 稀疏 / 编解码加速 · 在内存、时延与功耗预算内恢复精度

Knowledge Distillation

CE + KL / BILD / DKD / NormKD 可加权混合 · 可叠加任意下层

QAT 训练动力学

Scale EMA
渐进 / 混合精度位宽调度
skip_prob 量化噪声退火

结构 / 权重压缩

渐进式稀疏
L0 结构化剪枝
稀疏 $\cap$ 量化 联合优化

编解码加速算法

解码加速
Cache Eviction

量化友好表示 / 参数化

Rotate(Hadamard) · AdaRound ...

量化算子与训练加速底座

Triton 融合 QDQ · Stochastic Gate ...

稀疏化训练

通过减少有效权重存储和权重搬运量，缓解模型内存容量与访存带宽瓶颈。

01 稀疏度调度

从稠密预热开始，逐步提高目标稀疏度，避免训练早期破坏表示能力

02 分层差异化分配

敏感模块保持较低稀疏度，冗余模块承担更高压缩比例。


03 掩码更新策略

训练前中期动态更新连接，稳定后降低更新频率，兼顾搜索能力和训练开销。


04 软硬件协同

稀疏模式与 MTK 平台编码和执行约束对齐，收益最终落实到 BPV、带宽和解码速度。

权重稀疏化过程



稀疏化训练过程




稀疏化训练策略




稀疏化训练

- 内存收益: 75% 稀疏模型 BPV 降至 1.86, 内存占用降低 33.57%。



- 速度收益: 在对应 MTK 稀疏执行链路上, 解码速度提升 44.69%。



Cache Eviction

核心约束

内存: KV Cache 随序列长度线性增长, 迅速挤占端侧内存。


计算: 长序列扩大注意力与访存开销, 进一步放大首 token 和生成时延。

核心发现

注意力主要集中于少量关键 token; 大量历史 token 对当前输出贡献有限。

核心思路: 在固定预算下保留高价值记忆


结合注意力分数、层间信息与 key 表征, 在线淘汰低价值缓存并控制效果退化。




以可控精度损失换取可预测的内存上限

Eviction-aware Training (EAT)

挑战：KV Cache 随上下文线性增长；量化噪声会改变注意力排序，使缓存淘汰误差进一步放大




EAT 流程




Attention Sink 分析

- QAT 与 Eviction 并非正交：量化噪声会改变注意力排序，从而放大缓存淘汰误差。EAT算法可以缓解Attention Sink，从而提升full KV Cache下推理的效果

Eviction-aware Training (EAT)



开源Benchmark效果



业务数据上 50% eviction 的提升

收益边界

Cache Eviction 的效率收益取决于业务的 prefill / decode token 占比、平均输出长度和长尾分布。Decode 不占主导时，仅堆压缩比，边际收益有限。

训推一致

Chunked Prefill 下，EAT 必须与推理 eviction 同构：推理按 chunk 淘汰，训练也要按 chunk 淘汰，避免只在整段序列上对齐。

预算保护

Chunked Prefill 会多次打分，ChatML / system / sink 等控制 token 容易反复拿高分、挤占 KV 预算。需要单独限比例或降权，不能只看总保留率。

解码加速：投机解码

步骤 1：草稿模型生成 5 个 token，验证模型接受前 1 个

今天的天气

很好

✓ 接受

, 天上 没有 云朵

✗ 拒绝 (重新生成)

步骤 2：重新生成，接受前 3 个

今天的天气很好,

蓝蓝 的 天

✓ 接受

, 白白 的

✗ 拒绝

3次推理
接受 $1+3+3=7$ 个
token。

步骤 3：重新生成，全部接受，完成！

今天的天气很好,

蓝蓝的天白白的云


✓ 全部接受

[END]

解码加速的核心优化问题：

1. 提升草稿的接受率和接受长度。
2. 降低草稿模型的执行成本。

解码加速: CATS-SD



Draft model overconfidence问题


- 左图：在深层，某个错误 token 被打得特别高分。
- 右图：在浅层，某个错误 token 就被打得很高，一开始算力就花在错误分支上。

Tree-loss: Path-level calibration

- Cross-Entropy:
$$L_{\text{layer}}^{(d)} = -\log \frac{p_{c_*^{(d)}}}{\sum_{j=1}^{n_d} p_{c_j^{(d)}}}.$$
- Weight Decay:
$$w_d = \exp\left(-\frac{d-1}{\gamma}\right),$$
- Layer-loss:
$$L_{\text{layer}}^{(\text{tree})} = \frac{1}{\sum_{d=1}^D w_d} \sum_{d=1}^D w_d \cdot L_{\text{layer}}^{(d)}.$$
- Tree-loss:
$$L_{\text{tree}} = \frac{1}{m} \sum_{i=1}^m L_{\text{layer}}^{(\text{tree}_i)}.$$

- Tree-loss 增强 teacher model 所在路径 token 的置信度
- 同时，惩罚错误路径上的高置信度，tree loss 提供了 token-level loss 无法提供的监督

解码加速: CATS-SD



不同Tree Depth, 相比 baseline 均有10+%的 Acceptance Length提升

业务tips

- 端侧部署时, Draft model 进行 QAT 可以改善端侧推理 Acceptance Length, 也缓解MTK overture带来的输入分布漂移影响。图像与文本 embedding 的 min/max 差距过大, Draft 的输入 hidden states 需要加 RMSNorm, 避免尺度不一致直接进 Draft。
- BILD 蒸馏loss, 词表裁剪等tricks对于精度和效率提升有帮助。

03 QALFT 工程化架构

QALFT 训练框架

01 PTQ 损失不可控


浮点 LoRA 优化后统一量化，业务间相互影响

02 业务耦合重

任一 LoRA 更新都可能触发基模与多个业务重新量化

03 测试投入大

效果回退后需重新迭代整条端侧链路




业务解耦

可通过 QALFT 独立调整各业务效果，避免一次量化牵动全盘。


底层平台隔离

片商 SDK 与数据、训练框架隔离，片商间能力可复用。

QALFT 自动化平台




- ✓ 可配置、可断点、可并行调度、可局部重跑
- ✓ 自助式服务，全自动化流水线。
- ✓ 高效率，PTQ流程从天级别周期缩短到4小时。
- ✓ 10+业务支持：OS16.1 与 OS17.0 10+ 业务的成功交付。



04 端侧训练算法

端侧训练

端侧微调与个性化 · 数据不出设备 · 避免端侧化全链路流程



■ 零阶优化


零阶优化: $\hat{\mathbf{G}} = \frac{f(\mathbf{W} + \epsilon \mathbf{Z}, \mathcal{B}) - f(\mathbf{W} - \epsilon \mathbf{Z}, \mathcal{B})}{2\epsilon} \mathbf{Z}$

核心问题:


- 需要计算全量权重的梯度
- 收敛速度慢

解决方案:


- 引入稀疏扰动
- 降低搜索空间, 实现 variance reduction



(a) RTE



(b) BoolQ



(c) MNLI

可理论证明: 相比 standard MeZO, 至少 2× 以上收敛速度

零阶优化

TABLE III
EXPERIMENTAL RESULTS FOR COMMON-SENSE REASONING TASKS ON QWEN2.5-3B, 7B, 14B, AND 32B. WE REPORT THE ACCURACY(%) FOR ALL TASKS (HIGHER IS BETTER).

Models	Methods	ARC-E	ARC-C	HellaSwag	WinoGrande	OpenBookQA	Avg.
Qwen2.5-3B	Zero-shot	70.0	48.4	68.0	66.3	40.8	58.7
	MeZO	82.9	57.8	69.9	66.3	49.0	65.1
	WIS-MeZO	85.4	60.8	74.4	69.7	54.0	68.8
Qwen2.5-7B	Zero-shot	74.9	52.5	73.8	68.9	43.8	62.7
	MeZO	83.0	59.2	74.9	66.5	51.2	66.9
	WIS-MeZO	85.0	61.2	79.4	70.7	53.8	70.0
Qwen2.5-14B	Zero-shot	75.4	53.8	75.8	70.6	43.2	63.7
	MeZO	84.0	67.2	77.2	73.8	57.2	71.8
	WIS-MeZO	87.8	70.9	81.5	76.6	58.8	75.1
Qwen2.5-32B	Zero-shot	74.5	54.5	79.0	74.3	43.6	65.1
	MeZO	85.9	69.8	78.7	74.9	52.4	72.3
	WIS-MeZO	88.7	69.8	84.5	77.9	56.2	75.4

95%+ 稀疏下, WIS-MeZO 全面超越已有零阶优化方案

05 落地实践

落地实践


AI 一键闪记端侧版，全场景啥都能记

端侧高效多模态信息处理

4s 完成多次 4B 模型推理

响应速度不输云侧，无网也能随心记

端侧一键闪记



■ 落地实践

通话、会议、文档随心用

支持超长文档摘要

端侧摘要与信息抽取，稳定且高效

端侧摘要




■ 落地实践

极致的端侧出字速度
OPPO自研全模态并行译码加速技术

260 t/s

10秒内完成8张图片的同步理解
性能媲美云侧，达到行业领先水平

端侧极速Caption



06 总结与展望

■ 总结与展望

可能用在哪里



更广泛的垂域场景支持

端云协同的系统级智能体

多硬件平台统一训练、差异化交付

隐私约束下的本地个性化轻量适配

技术上还需要优化什么



长上下文的高效注意力、KV Cache 管理、高效架构

更低存储与带宽：低比特量化训练等

端侧多模态理解与 Agent 规划统一优化

全链路工程化、跨平台自动化与功耗/温升评测闭环

QCon

全球软件开发大会

上海
站

大模型正在重新定义软件

Large Language Model Is Redefining The Software

2026 年 10 月 22-24 日 / 上海建工浦江皇冠假日酒店



参会
咨询

**专题：从 App 到 Agent：字节跳动
Supabase 的 Agent-Native 规模化实践**

专题演讲嘉宾：张国强

字节跳动 / 资深技术专家



**专题：复杂业务 Agent 的持续进化：
快手电商导购的 Harness Loop 实践**

专题演讲嘉宾：包磊

快手 / 资深技术专家



**专题：从 Harness 到 Loop：阿福 Agent
小队如何处理持续涌入的线上 Badcase**

专题演讲嘉宾：肖汉松

蚂蚁集团 / 阿福 Harness 架构组负责人



**专题：AI Coding 在大型客户端工程中的
落地实践——从通才模型到专才 Agent**

专题演讲嘉宾：杨凯

小红书 / 客户端基础技术负责人



**专题：AI 时代的一人公司：从 Idea 到
Growth 的完整 workflow**

专题演讲嘉宾：casa

独立开发



**专题：Agent 驱动的全平台 GUI 持续
验证实践**

专题演讲嘉宾：王政达

微软 / SENIOR SOFTWARE ENGINEER



THANKS

探索 AI 应用边界

Explore the limits of AI applications

AiCon

全球人工智能开发与应用大会