

从 HAMi 到 HAMi-DRA: 异构环境的算力资源管理实践

演讲人：杨守仁

范式智能 / 系统研发专家, HAMi Maintainer

AiCon

全球人工智能开发与应用大会

极客邦科技 2026 年会议规划

促进软件开发及相关领域知识与创新的传播



参会咨询

InfoQ 技术大会

QCon

上海站

全球软件开发大会

大模型正在重新定义软件

Large Language Model Is Redefining
The Software

10月22-24日 / 上海建工浦江皇冠假日酒店

· AI Agent

· Vibe Coding

· 智能可观测

· 推理基建

· 模型攻防

· AI x 创造力

InfoQ 技术大会

AiCon

北京站

全球人工智能开发与应用大会

探索 AI 应用边界

Explore the limits of AI applications

12月18-19日 / 北京

· 大模型架构创新

· 多模态 AI 产业融合

· 具身智能

· AI for Science

· 大模型安全

目录

01 摘要

02 背景和动机

03 HAMi 的设计和实现

04 HAMi DRA 的设计和实现

05 总结和展望

01 摘要

摘要



时代背景

介绍国产算力的高速发展背后带来的异构算力管理的挑战



回顾与困境

剖析传统 Device Plugin 的架构限制，以及 HAMi 现有方案面临的现实瓶颈。



机遇与挑战

探讨 Kubernetes DRA 带来的云原生架构变革，以及实践落地中的真实问题。



破局与展望

介绍 HAMi-DRA 的核心解决方案，并讨论面向未来的演进和挑战

02 背景和动机

What's HAMi

CNCF Incubation

Scheduling &
1



HAMi

Open Source

Ecosystem

Broad accelerator
ecosystem



。 。 。

Heterogeneous

Cross-industry

Real-world adoption
stories



Adoption

Worldwide

HAMi is advanced by
contributors from the
community and industry

Community



异构设备管理的挑战



统一的异构算力支持

集中管理



多维度的设备资源描述

资源建模



无入侵的算力共享能力


算力共享方案



多样的设备调度能力

调度策略

Device Plugin 的限制



03 HAMi 的设计和实现

HAMi 的设计和实现


Bypass ResourceName

1. 接管特定的资源名称
2. 实现多维度资源配置

Node selection at Filter

1. 降低实现成本
2. 提升调度性能

设计思路



No Scheduler Plugin

1. 减小社区的维护压力
2. 兼容更多的用户环境
3. 兼容更多的调度器

No bypass Device Plugin

1. 解耦依赖特定的 Container Runtime
2. 部署友好

HAMi 的设计和实现

突破 Device Plugin 的限制

设备信息


- Annotations of Node
- Annotations of Pod

调度器扩展

- With managedResources
- Topology Aware Scheduling

节点锁

- Scheduler – Bind
- Device Plugin - Allocate



HAMi 的设计和实现


HAMi 的整体架构

Control Plane

- HAMi Webhook
- HAMi Scheduler Extender

Worker Node

- Device Plugin
- HAMi-Core



HAMi 生产实践

Fhancy Group

1. Zero Changes
2. Bring 10 more vendors supports for ModelHub XC

SNOW CORP.

1. 55% cost reduction
2. GPU Sharing via HAMi
3. 2x fewer GPUs



SF Express

1. Up to 57% GPU Saving
2. Up to 100% utilization improvement

China Merchants Bank

1. 100% hardware pool utilization through topology-aware scheduling
2. 30% reduction in cross-machine scheduling for distributed training workloads

04 HAMi DRA 的设计和实现

HAMi 的问题和挑战

1 ResourceQuota 计量问题

需要额外的 Quota 实现

2 Preemption 的兼容问题

由于 Extender API 的限制，在支持 Preemption 等 Kubernetes 调度功能时拙荆见肘

TradeOffs

3 调度性能劣化

当在单个 Node 上同时调度多个 Pod 的情况下，由于节点锁的排它性，导致并发调度退化为串行调度

4 异常死锁

系统的默认锁定时长为5分钟，在创建过程中，可能因为请求失败等问题导致节点无法解锁

What's DRA

DRA API

- DeviceClass
- ResourceSlice
- ResourceClaim
- ResourceClaimtemplate

DRA Features

- Consumable Capacity
- Partitionable Devices

DRA Plugin

- Scheduler
- Kubelet

DRA Drivers

- NVIDIA DRA Drivers
- Ascend DRA Drivers
- DRA Driver CPU



DRA Concepts

HAMi DRA 的设计和实现

HAMi-Core DRA Driver

发布设备信息

- Device Attributes


- Capacity

处理 ResourceClaim

- 注入环境变量
- 创建共享目录和配置文件

清理 ResourceClaim

- 清理共享目录



HAMi DRA的设计和实现

调度性能说明


调度性能提升

从实验的结果来看，HAMi-DRA 借助 DRA 自身的调度系统，避免了节点锁带来的性能衰退问题

完善的设备生命周期管理

UnprepareResourceClaims 接口让 HAMi-Core 引入的临时文件可以在合适的时机被清理

Comparison of Pod Creation Time



HAMi DRA的设计和实现


HAMi DRA Webhook

多维度资源自动转换

HAMi-DRA 的 Webhook 能将 HAMi 中定义的多维度的 ResourceName 自动转换成 DRA 中的 ResourceClaim

ResourceClaim 生命周期管理

通过将 ResourceClaim 的生命周期和 Pod 的生命周期绑定，能够将自动创建的 ResourceClaim 及时清理



HAMi DRA 的落地实践

Topology Aware Scheduling


设备属性字段

通过设置 ResourceClaim 中的 constraints 字段，可以让分配的资源都满足相同的属性字段

与其他 DRA Driver 协同调度

设置与 CPU 资源相同的 NUMA 属性字段，可以实现基于 NUMA 的拓扑感知调度，相似方案也已扩展到网卡等资源

03 / SCHEMATIC: NUMA-AWARE TOPOLOGY ALIGNMENT



TOPOLOGY-AWARE SCHEDULING (TAS)

HAMi-DRA 结合 dra-driver-cpu 插件，可实现对底层物理 NUMA 节点的原生级深度感知。自动完成 CPU 算力核心与异构加速卡槽位的精准对齐与分配，从根本上避免跨 Socket 互联总线瓶颈。

HAMi DRA 的落地实践

Heterogeneous

差异化资源配置

ResourceClaim 支持异构的资源配置, 配合 firstAvailable 字段设置多种分配方案时会有惊喜

针对 Pipeline 并行的资源分配

在 Pipeline 并行的场景中, 让应用层感知算力资源的分配, 可以最大化算力资源的使用

```
apiVersion: resource.k8s.io/v1
kind: ResourceSlice
metadata:
  name: k8s-dra-driver-cluster-worker-hami-core-gpu.project-hami.ikffwb
spec:
  driver: hami-core-gpu.project-hami.io
  nodeName: k8s-dra-driver-cluster-worker
  pool:
    generation: 1
    name: k8s-dra-driver-cluster-worker
    resourceSliceCount: 1
  devices:
    - allowMultipleAllocations: true
      attributes:
        resource.kubernetes.io/pciRoot:
          string: pci0000:80
        type:
          string: hami-gpu
      capacity:
        memory:
          requestPolicy:
            default: 11Gi
            validRange:
              max: 11Gi
              min: 1Mi
              step: 1Mi
            value: 11Gi
          name: hami-gpu-3
```

```
apiVersion: resource.k8s.io/v1
kind: ResourceClaim
metadata:
  namespace: test-dra
  name: double-gpu-0
spec:
  devices:
    requests:
      - name: double-gpu-0-0
        exactly:
          deviceClassName: hami-core-gpu.project-hami.io
          capacity:
            requests:
              cores: 30
              memory: "4Gi"
      - name: double-gpu-0-1
        exactly:
          deviceClassName: hami-core-gpu.project-hami.io
          capacity:
            requests:
              cores: 60
              memory: "8Gi"
```

HAMi DRA 的问题和挑战

DRA 的落地阻力

K8s v1.34 or higher

HAMi DRA 所以依赖的 Consumable Capacity 功能依赖 v1.34 以上的版本，其它的 DRA 特性可能依赖更高的版本

高版本依赖

有限的厂商支持

目前 HAMi 社区完成了对于 NVIDIA 和海光 DCU 的 DRA Driver 适配，Ascend 和 Enflame 的适配还在推进中

国产算力支持

Scoring 缺失

在设备调度层面，DRA 的 Scoring 功能是缺失，对于特性化的调度要求支持有限

调度能力


学习和适配 DRA

DRA 引入的新的概念对于部署和维护集群的同学有一定的学习成本，HAMi 社区希望能通过 HAMi DRA 的 Webhook 降低这一成本

迁移成本


HAMi DRA 的问题和挑战

DRA Drivers on the way



05 总结和展望

HAMi & HAMi DRA



HAMi & HAMi DRA

更多异构设备支持

1. MetaX
2. Iluvatar CoreX

兼容 K8s 标准的设备属性

resource.kubernetes.io/pcieRoot



更多 DRA 特性适配

1. List Attributes
2. Partitionable Devices

更多的调度器集成

1. Volcano
2. Kueue

What's next in HAMi-DRA

QCon

全球软件开发大会

上海
站

大模型正在重新定义软件

Large Language Model Is Redefining The Software

2026 年 10 月 22-24 日 / 上海建工浦江皇冠假日酒店



参会
咨询

**专题：从 App 到 Agent：字节跳动
Supabase 的 Agent-Native 规模化实践**

专题演讲嘉宾：张国强

字节跳动 / 资深技术专家



**专题：复杂业务 Agent 的持续进化：
快手电商导购的 Harness Loop 实践**

专题演讲嘉宾：包磊

快手 / 资深技术专家



**专题：从 Harness 到 Loop：阿福 Agent
小队如何处理持续涌入的线上 Badcase**

专题演讲嘉宾：肖汉松

蚂蚁集团 / 阿福 Harness 架构组负责人



**专题：AI Coding 在大型客户端工程中的
落地实践——从通才模型到专才 Agent**

专题演讲嘉宾：杨凯

小红书 / 客户端基础技术负责人



**专题：AI 时代的一人公司：从 Idea 到
Growth 的完整 workflow**

专题演讲嘉宾：casa

独立开发



**专题：Agent 驱动的全平台 GUI 持续
验证实践**

专题演讲嘉宾：王政达

微软 / SENIOR SOFTWARE ENGINEER



THANKS

探索 AI 应用边界

Explore the limits of AI applications

AiCon

全球人工智能开发与应用大会