

DeepSeek-V4

百万 Token 上下文推理优化

SGLang 的系统设计与实现

Yuhao Yang · SGLang / RadixArk



极客邦科技 2026 年会议规划

促进软件开发及相关领域知识与创新的传播



参会咨询

InfoQ 技术大会

QCon 上海站
全球软件开发大会

大模型正在重新定义软件
Large Language Model Is Redefining
The Software

10月22-24日 / 上海建工浦江皇冠假日酒店

· AI Agent

· Vibe Coding

· 智能可观测

· 推理基建

· 模型攻防

· AI x 创造力

InfoQ 技术大会

AiCon 北京站
全球人工智能开发与应用大会

探索 AI 应用边界
Explore the limits of AI applications

12月18-19日 / 北京

· 大模型架构创新

· 多模态 AI 产业融合

· 具身智能

· AI for Science

· 大模型安全

DeepSeek-V4: 模型规模与两项架构变化

1.6T

总参数

49B

每 Token 激活

384 / 6

路由专家 / 每 Token 激活

1M

Token 上下文

V4-Flash: 284B 总参数, 单 Token 激活 13B

MoE 路由专家权重与 CSA Indexer 的 QK 路径采用 FP4


mHC

残差状态扩展为四路, 并通过受约束映射完成混合与写回

混合注意力

每层使用 SWA, 并选择 CSA 或 HCA

mHC: 残差流由一路扩展为四路



每层通过受约束的映射完成四路残差状态的读入、混合与写回

混合注意力: SWA + (CSA 或 HCA)

■ TopK-selected ■ dense read ■ Q

RAW
N tokens



Q current query


SWA
always active



last 128 raw
uncompressed

+ one of:

CSA
C4 sparse
4:1 · Top-K



Top-K (1024 for Pro)
of N/4 cells

OR

HCA
C128 dense
128:1 · full read




N/128 · all read
every compressed cell

Per-layer attention = SWA + (C4 sparse OR C128 dense)


每层读取: 最近 128 个未压缩 Token, 加上 Top-K 稀疏 C4 条目或完整 C128 稠密流。

ShadowRadix: 统一索引三类 KV



■ HiCache: 可复用前缀的分层存储


- Unified Radix Cache 判断哪些状态可以复用
- HiCache 决定这些状态存放在 GPU、CPU 还是外存
- 数据迁移后，前缀身份和复用规则保持不变



DeepSeek-V4-Flash 多轮对话：稳定阶段 L3 命中率约 98%


■ HiSparse: GPU 仅驻留活跃的 C4 KV

- CSA 每轮只读取 Indexer 选中的少量 C4 KV 页面
- CPU 保存完整 C4 KV, GPU 只保存活跃工作集
- 缺失页面按需换入, 新生成的 C4 KV 异步备份到 CPU



长上下文服务: Token 容量与吞吐最高可达基线的 3x


■ DSpark: 并行生成整块草稿, 动态选择验证长度



Backbone 一次前向生成整块草稿, Prefix Scheduler 按前缀存活概率选择验证长度。

■ SGLang: 按请求裁剪验证长度


每个请求只保留需要验证的前缀，裁掉的 Token 不进入验证 Batch。



固定宽度需要 24 个位置；Ragged Verify 只计算 14 个有效 Token。


FlashCompressor: HBM 往返由五次降至两次

bias、softmax 与 scale-dot 在片上融合执行



中间结果留在寄存器和共享内存，HBM 只承担输入与输出

Lightning TopK: 基于局部直方图的 Top-K 选择



100 μ s $\rightarrow$ 15 μ s

演示配置 K=512; V4-Pro 配置 K=1024

MegaMoE: 融合专家通信与计算

Dispatch、两次专家 GEMM、SwiGLU 与 Combine 在一个 Mega-kernel 中重叠执行

普通执行



串行执行 · 通信与计算相互等待

W4A8 (默认)

FP4 权重 · FP8 激活

W4A4

FP4 权重 · FP4 激活

E2M1 Pack · MXF4 Mainloop

Blackwell only


MegaMoE



通信与不同专家波次重叠执行

W4A4: 激活槽位占用减半, 专家 GEMM 切换到 MXF4。

多流重叠：三条旁路与主流并行执行




主流继续计算时，KV 写入、压缩和 Indexer 已经并行推进

■ 并行策略： 五种方式分别解决不同瓶颈

方式	拆分什么	在 V4 中的作用
TP	模型张量	解决单卡容量与单层计算
DP Attention	请求批次与 KV 状态	高并发下分摊 KV 和调度
EP	MoE 专家	将专家计算分布到多卡
Prefill CP	输入序列	分摊长输入的 Prefill 计算
PD 分离	推理阶段	Prefill 与 Decode 独立扩缩容

实际组合仍受互联拓扑和实现版本约束

Prefill CP: 沿序列维度切分长输入




CP=4 时，每个 rank 只处理四分之一的输入序列



端到端性能: GB300 NVL72 峰值约 11.5K tok/s/GPU

DeepSeek-V4-Pro · FP4 · ISL/OSL=8K/1K · InferenceX

缓存、稀疏计算、内核融合与并行策略共同形成端到端收益。



QCon

全球软件开发大会

上海
站

大模型正在重新定义软件

Large Language Model Is Redefining The Software

2026 年 10 月 22-24 日 / 上海建工浦江皇冠假日酒店



参会
咨询

**专题：从 App 到 Agent：字节跳动
Supabase 的 Agent-Native 规模化实践**

专题演讲嘉宾：张国强

字节跳动 / 资深技术专家



**专题：复杂业务 Agent 的持续进化：
快手电商导购的 Harness Loop 实践**

专题演讲嘉宾：包磊

快手 / 资深技术专家



**专题：从 Harness 到 Loop：阿福 Agent
小队如何处理持续涌入的线上 Badcase**

专题演讲嘉宾：肖汉松

蚂蚁集团 / 阿福 Harness 架构组负责人



**专题：AI Coding 在大型客户端工程中的
落地实践——从通才模型到专才 Agent**

专题演讲嘉宾：杨凯

小红书 / 客户端基础技术负责人



**专题：AI 时代的一人公司：从 Idea 到
Growth 的完整 workflow**

专题演讲嘉宾：casa

独立开发



**专题：Agent 驱动的全平台 GUI 持续
验证实践**

专题演讲嘉宾：王政达

微软 / SENIOR SOFTWARE ENGINEER



谢谢

DeepSeek-V4 百万 Token 上下文推理优化
SGLang 的系统设计与实现

github.com/sgl-project/sglang · lmsys.org/blog